Cahier des charges – Sujet 4 : Données médicales hétérogènes et manquantes (focus imputation, fusion et diagnostic)

Proposé par Ikram Chourib

Matière « Analyse et restitution ». Le binôme doit mesurer comment le taux et le mécanisme des valeurs manquantes, et la méthode d'imputation choisie, changent la qualité d'un diagnostic proposé, puis dire jusqu'où on peut lui faire confiance. Soutenance le 15/03/2027.

1. Contexte et objectifs

Un dossier patient réel mélange mesures numériques, variables catégorielles, texte libre et parfois images, avec beaucoup de manquants et d'incohérences. La question est : **comment préparer ces données pour proposer un diagnostic fiable, et jusqu'où faire confiance à ce diagnostic ?** Le système reste une aide à la décision, jamais un diagnostic médical.

Objectifs mesurables :

- Explorer, nettoyer et cartographier les valeurs manquantes.
- Analyser le mécanisme des manquants (MCAR, MAR, MNAR).
- Comparer au moins cinq stratégies d'imputation, dont un modèle qui gère nativement les manquants.
- Injecter des manquants à 10, 30 et 50 %, selon les trois mécanismes, et mesurer l'effet sur le diagnostic.
- Fournir un diagnostic calibré (probabilité fiable), expliqué par SHAP.
- Livrer un petit tableau de bord : diagnostic proposé, confiance, variables décisives.

2. Contributions attendues du binôme

La contribution est **une étude comparative honnête de l'imputation et un diagnostic dont la confiance est mesurée**. Le binôme doit livrer :

1. **Une cartographie des manquants** et une analyse argumentée de leur mécanisme.
2. **Un protocole d'injection contrôlée** des manquants (taux × mécanisme), réutilisable.
3. **Une étude comparative de l'imputation** : erreur d'imputation et performance du diagnostic, avec leur stabilité.
4. **Un modèle de diagnostic calibré et expliqué** (courbe de calibration, SHAP).
5. **Un rapport sur les limites** : biais de population, fuite de données, données peu représentatives, RGPD.
6. **Un tableau de bord** de démonstration.

3. Données

Jeu de données	Contenu	Intérêt pédagogique	Accès
Chronic Kidney Disease (CKD)	Dossiers de patients avec 24 variables cliniques et biologiques (âge, tension, densité urinaire, albumine, sucre, globules rouges, urée, créatinine, sodium, potassium, hémoglobine, hypertension, diabète, appétit, œdème, anémie…) et une étiquette `ckd` / `notckd`. 11 variables numériques, le reste catégoriel. Valeurs manquantes présentes. Le jeu d'origine compte 400 patients.	Mélange réel de mesures numériques et de variables catégorielles, avec des valeurs manquantes à traiter (imputation, indicateurs d'absence). Permet d'étudier comment préparer les données, puis d'évaluer la fiabilité du diagnostic : calibration des probabilités, incertitude, règle d'abstention quand le système n'est pas assez sûr. Jeu petit, donc rapide à manipuler pendant un hackathon.	Kaggle : colearninglounge, fichier `kidney_disease_train.csv` ; source d'origine : UCI Machine Learning Repository, licence CC BY 4.0

Règles obligatoires :

- **Séparer entraînement et test avant toute imputation ou normalisation.** Imputer avant de séparer est une fuite de données.
- Mettre imputation, normalisation et modèle dans un `Pipeline` scikit-learn évalué par validation croisée stratifiée.
- Remplacer les zéros impossibles (glycémie à 0, IMC à 0) par des manquants et le documenter.
- Pour le texte sans MIMIC : comptes rendus simulés par gabarit, **sans jamais y écrire le diagnostic**.
- Aucune donnée de patient réel dans le dépôt GitHub.

4. Modèles et méthodes à utiliser

Imputation :

Méthode	Principe	Avantage	Limite	Outil
Suppression des lignes	Garder les patients complets	Simple	Perte de données, biais si non MCAR	pandas
Moyenne / médiane	Valeur centrale de la variable	Référence rapide	Écrase la variance et les corrélations	`SimpleImputer`

Méthode	Principe	Avantage	Limite	Outil
kNN	Moyenne des k patients les plus proches	Respecte la structure locale	Sensible à l'échelle, lent sur grands jeux	`KNNImputer`
MICE	Chaque variable prédite par les autres, en boucle	Standard en statistique médicale	Hypothèse MAR	`IterativeImputer`
MissForest	MICE avec des forêts aléatoires	Gère les non-linéarités et le mixte	Plus lent	`IterativeImputer` + `RandomForestRegressor`
Autoencodeur (avancé)	Reconstruction des valeurs masquées	Capte des relations complexes	Demande plus de données	PyTorch
Gestion native	L'arbre apprend où envoyer les manquants	Aucun prétraitement	Moins interprétable	XGBoost, LightGBM

Option à tester avec chaque méthode : ajouter une **colonne indicatrice de manquant** par variable, utile quand le manquant est informatif.

Diagnostic : régression logistique (référence interprétable), arbre de décision, Random Forest, gradient boosting (XGBoost ou LightGBM), réseau de neurones (MLP) en option.

Fusion de modalités (niveau avancé) :

- **Précoce** : concaténation des variables tabulaires et des embeddings de texte.
- **Tardive** : un modèle par source, puis vote ou empilement (stacking).
- **Embeddings de texte** : ClinicalBERT (anglais), CamemBERT ou DrBERT (français médical).

5. Étapes de réalisation

1. **Cadrage** : choisir le niveau et les jeux de données, créer le dépôt GitHub. Demander l'accès MIMIC-IV dès la séance 1 si le niveau avancé est visé.
2. **Exploration** : distributions, corrélations, cartographie des manquants (`missingno` : matrice, carte de chaleur des co-manquants).
3. **Nettoyage** : règles médicales de plausibilité (ex. pression systolique entre 70 et 250 mmHg), méthode IQR, harmonisation des unités, encodage, normalisation.
4. **Analyse du mécanisme** : comparer les patients avec et sans manquant (tests statistiques), prédire l'indicateur de manquant à partir des autres variables. Discuter si le manquant est informatif (un examen non prescrit veut dire quelque chose).
5. **Protocole d'injection** : partir d'un jeu complet, injecter 10, 30 et 50 % de manquants :
    - MCAR : au hasard ;
    - MAR : la probabilité dépend d'une autre variable observée (ex. l'âge) ;

    - MNAR : la probabilité dépend de la valeur elle-même (ex. insuline élevée plus souvent absente).
6. **Imputation** : chaque méthode, dans un `Pipeline`, avec et sans colonnes indicatrices ; RMSE sur les valeurs injectées.
7. **Diagnostic** : chaque modèle × chaque imputation, validation croisée stratifiée à 5 plis, répétée 10 fois.
8. **Calibration et explication** : courbe de calibration, score de Brier, recalibration (Platt ou isotonique), SHAP global et par patient.
9. **Robustesse** : entraîner sur un hôpital et tester sur un autre (UCI Heart) ; simuler un nouveau patient avec des variables absentes.
10. **Restitution** : tableau de bord, rapport sur les limites, présentation.

6. Points de challenge

Challenge	Pourquoi c'est difficile	Piste de solution
Fuite de données	Imputer ou normaliser avant de séparer utilise l'information du test	`Pipeline` scikit-learn dans la validation croisée
Manquants déguisés	Des zéros ou des « 999 » passent pour des valeurs	Règles de plausibilité écrites et appliquées avant tout
MNAR non vérifiable	Les données seules ne prouvent pas un MNAR	L'argumenter avec le contexte médical, le simuler pour en mesurer l'effet
Déséquilibre des classes	Peu de malades : l'accuracy trompe	AUC, sensibilité, F1, pondération des classes
Petits jeux de données	Grande variance entre découpages	Validation croisée répétée, moyenne ± écart-type
Biais de population	Un modèle appris à Cleveland se dégrade ailleurs	Test inter-hôpitaux, discussion de la représentativité
Probabilités trompeuses	Un modèle peut bien classer mais afficher 95 % à tort	Calibration et score de Brier
RGPD et éthique	Les données de santé sont des données sensibles	Données publiques anonymisées, note RGPD, mention « aide à la décision »

7. Métriques d'évaluation

Métrique	Ce qu'elle mesure	Sens	Remarque
AUC-ROC	Capacité à classer malade / non malade	Plus haut = mieux	Métrique principale ; ajouter l'AUC-PR si les malades sont rares
Sensibilité	Part des malades détectés	Plus haut = mieux	Prioritaire en dépistage
Spécificité	Part des non-malades correctement écartés	Plus haut = mieux	À lire avec la sensibilité
F1	Équilibre précision / rappel	Plus haut = mieux	Indiquer le seuil
Score de Brier et courbe de calibration	Fiabilité des probabilités affichées	Brier plus bas = mieux	Indispensable pour afficher une « confiance »
RMSE d'imputation	Écart entre valeur imputée et vraie valeur injectée	Plus bas = mieux	Variables normalisées ; taux d'erreur pour les catégorielles
Stabilité	Écart-type des métriques sur 10 répétitions	Plus bas = mieux	Sert à dire si deux méthodes diffèrent vraiment

8. Comment interpréter les résultats

- **Bonne imputation ne veut pas dire bon diagnostic.** La moyenne a souvent une mauvaise RMSE mais peut garder une AUC correcte. Toujours montrer les deux, côte à côte.
- **Le mécanisme change le classement.** Une méthode qui gagne en MCAR peut perdre en MNAR. Lire le tableau mécanisme par mécanisme.
- **Si les colonnes indicatrices améliorent l'AUC, le manquant est informatif.** C'est un résultat médical intéressant, pas un artefact.
- **AUC et calibration sont deux questions différentes.** « Le modèle classe-t-il bien ? » et « La probabilité affichée est-elle vraie ? ». Un tableau de bord doit afficher une probabilité calibrée.
- **SHAP explique le modèle, pas la maladie.** Une variable très imputée peut sembler importante à tort. Ne jamais en tirer de lien de cause.
- **Différence plus petite que l'écart-type : méthodes équivalentes.** Le dire clairement plutôt que déclarer un gagnant.
- **Une chute de performance entre hôpitaux est un résultat.** Elle montre la limite de généralisation et doit apparaître dans le rapport sur les limites.

9. Travail en binôme

Chaque membre a un périmètre principal, mais **les deux doivent savoir expliquer tout le projet** le jour de la soutenance.

Rôle	Membre A « Données et imputation »	Membre B « Diagnostic et restitution »
Données	Exploration, cartographie des manquants, nettoyage	Règles de plausibilité médicale, encodage
Manquants	Analyse du mécanisme, protocole d'injection	Colonnes indicatrices, cas du nouveau patient incomplet
Méthodes	Toutes les imputations, RMSE	Modèles de diagnostic, fusion de modalités
Évaluation	Stabilité sur répétitions	AUC, calibration, SHAP, test inter-hôpitaux
Restitution	Note RGPD et rapport sur les limites	Tableau de bord
En commun	Expérience centrale, interprétation, rapport, présentation	Expérience centrale, interprétation, rapport, présentation

Règles de fonctionnement :

- Une branche par fonctionnalité ; chaque fusion (pull request) est relue par l'autre membre.
- Les commits des deux membres doivent apparaître régulièrement dans l'historique GitHub.
- Un fichier `CONTRIBUTIONS.md` liste qui a fait quoi, mis à jour à chaque séance.
- Un journal des expériences (mécanisme, taux, imputation, modèle, résultat) dans `results/experiences.csv`.
- Point hebdomadaire de 30 minutes entre les membres pendant le travail autonome.

10. Planning et organisation

Étape	Date et horaire	Travail en séance	Attendu en fin d'étape
Séance 1 – Lancement	Mardi 10/11/2026, 14h00–17h30	Présentation du sujet, choix du niveau, création du dépôt, chargement des données, cartographie des manquants, demande d'accès MIMIC si besoin	Dépôt GitHub avec un README de cadrage (problématique, niveau, jeux de données, rôles)
Travail autonome	Novembre – décembre	Nettoyage, analyse du mécanisme, protocole d'injection, premières imputations	Pipeline de référence (médiane + régression logistique) évalué sans fuite
Séance 2 – Point d'avancement	Mardi 05/01/2027, 9h00–12h30	Présentation de l'exploration et de la référence (5 min), retour de l'enseignant, lancement de l'expérience centrale	Cartographie des manquants + premiers résultats MCAR

Étape	Date et horaire	Travail en séance	Attendu en fin d'étape
Travail autonome	Janvier – février	Expérience complète (3 mécanismes × 3 taux), calibration, SHAP, robustesse, tableau de bord	Première version du rapport
Séance 3 – Revue avant soutenance	Lundi 01/03/2027, 9h00–12h30	Revue des résultats et des interprétations, test du tableau de bord, plan de la présentation	Liste de corrections à faire avant le dépôt
Dépôt final	Vendredi 12/03/2027, 23h59 (proposition, à confirmer)	Gel du code (tag `v1.0`), rapport et présentation déposés	Tous les livrables
Soutenance	Lundi 15/03/2027, 9h00–17h30	Passage de 5 à 10 minutes par binôme, puis questions	Présentation + démonstration

11. Livrables

- ☐ **Code fonctionnel sur GitHub** (notebooks reproductibles + modules Python)
  - README : installation, téléchargement des données, commandes pour reproduire chaque tableau ;
  - `requirements.txt` avec versions fixées, graines fixées ;
  - aucune donnée de patient réel dans le dépôt (`.gitignore`) ;
  - tag `v1.0` sur la version soutenue.
- ☐ **Rapport technique** (15 à 20 pages hors annexes) : contexte, données, nettoyage, mécanismes, protocole, résultats, interprétation, **limites du diagnostic** (biais, représentativité, fuite), note RGPD et anonymisation.
- ☐ **Démonstration** : tableau de bord Streamlit ou Dash (saisie d'un patient, même incomplet → diagnostic proposé, probabilité calibrée, variables décisives SHAP), plus une vidéo de secours de 1 à 2 minutes.
- ☐ **Résultats et interprétations** : étude comparative de l'imputation (taux × mécanisme × méthode), calibration, SHAP, robustesse inter-hôpitaux.
- ☐ **Présentation PowerPoint** de 6 à 10 diapositives.

Structure de dépôt conseillée :

```
medical-manquants-diagnostic/
├── README.md
├── requirements.txt
├── CONTRIBUTIONS.md
├── data/             # vide, rempli par scripts/download.py
├── notebooks/        # 01_exploration, 02_nettoyage, 03_imputation, 04_diagnostic
├── src/
│   ├── cleaning/     # règles de plausibilité
│   ├── missing/      # injection MCAR, MAR, MNAR
```

```
│   ├── imputation/   # méthodes comparées
│   └── models/       # diagnostic, calibration, SHAP
├── results/          # tableaux CSV et figures
├── app/              # tableau de bord
└── docs/             # rapport, note RGPD, présentation
```

12. Soutenance (5 à 10 minutes)

Les deux membres prennent la parole. Une diapositive = un message et un chiffre clé.

Partie	Durée indicative	Contenu
Problématique	1 min	Cartographie des manquants d'un vrai jeu de données
Données et protocole	1 min	Nettoyage, mécanismes, schéma d'injection, pipeline sans fuite
Résultats	2 à 3 min	Imputation × mécanisme × taux, calibration
Démonstration	1 à 2 min	Un patient incomplet dans le tableau de bord, avec ses variables décisives
Limites et recommandation	1 min	Méthode recommandée, biais, RGPD, « aide à la décision »

Questions probables du jury :

- Où faites-vous l'imputation par rapport au découpage entraînement / test ?
- Comment savez-vous si un manquant est MNAR ?
- La probabilité affichée est-elle fiable ?
- Qui a fait quoi dans le binôme ?